

Экономическая сводка проекта базы научных статей

Краткий документ для обсуждения с экспертом и подготовки экономического слайда. Оценка дана без учета ФОТ команды разработки и управленческих расходов.

Рекомендуемая цифра для слайда

≈ 18 млн ₽

запуск и первичное
наполнение

Рабочий ежегодный OPEX

≈ 2,3 млн ₽

поддержка и
пополнение

Масштаб корпуса

≈ 6,2 млн

документов в трех
источниках

Ключевой вывод. Основной драйвер затрат в этом проекте — не PostgreSQL, не сайт и не парсеры, а массовая AI-обработка всего корпуса через продвинутое API Яндекса. Инфраструктура относительно недорогая; дорого именно индустриальное обогащение миллионов статей.

Что включено в оценку

- 3 парсера источников, контур ETL/обработки, основная БД на PostgreSQL, сайт/веб-интерфейс, резервное хранение и регулярное обновление базы.
- Первичная загрузка полного корпуса статей из arXiv, CyberLeninka и ChinaXiv с последующей AI-обработкой метаданных, аннотаций и тематической структуры.
- Регулярная дозагрузка новых публикаций и их обработка в эксплуатационном режиме.
- В оценку не включены зарплаты программистов, аналитиков, DevOps/администрирования, юридическое сопровождение и офисные расходы.

Ключевые допущения

- Рабочая оценка масштаба текущего корпуса: около 6,2 млн документов.
- Рабочая оценка ежегодного пополнения: около 450–500 тыс. новых документов в год.
- Базовый промышленный сценарий AI-обработки: title + abstract + метаданные, а не сплошной полнотекстовый разбор всего PDF-архива.
- Платформа хранения и БД: облачная инфраструктура с PostgreSQL и объектным хранилищем; ориентир по тарифам — Yandex Cloud.

Структура стоимости

1) Разовый бюджет запуска и первичного наполнения

Статья затрат	Оценка	Комментарий
Инфраструктура первого года	1,0–1,3 млн ₽	Веб/API-инстансы, ETL/worker, управляемый PostgreSQL, объектное хранение, бэкапы, сеть, мониторинг.
Первичная AI-обработка корпуса	14–18 млн ₽	Массовый прогон всего архива через продвинутый Yandex API при сценарии обработки title + abstract + метаданных.
Резерв на повторные прогоны и сервисные накладные	0,7–1,0 млн ₽	Исправление ошибок парсинга, повторная обработка части массива, ускоренный импорт, рост хранилища.
Итого защищаемый бюджет запуска	17–20 млн ₽	Рекомендуемая цифра для презентации: около 18 млн ₽.

2) Ежегодная поддержка после запуска

Статья затрат	Оценка	Комментарий
Инфраструктурный контур	1,0–1,3 млн ₽/год	Постоянная эксплуатация БД, сайта, парсеров, хранения и базового облачного окружения.
AI-обработка новых статей	1,1–1,4 млн ₽/год	Прогон ежегодного потока новых публикаций через Yandex API.
Итого ежегодный OPEX	2,1–2,7 млн ₽/год	Рекомендуемая цифра для слайда: около 2,3 млн ₽/год.

Почему эти цифры выглядят обоснованно

- Даже при production-архитектуре облачная инфраструктура здесь стоит умеренно; ее вклад в бюджет меньше, чем вклад AI-обработки.
- В проекте масштаба нескольких миллионов документов стоимость обогащения корпуса LLM-моделью становится главным финансовым фактором.
- Поэтому экономически корректно показывать проект не как «сайт с БД», а как национальную обработанную базу научных знаний.
- Для жюри и эксперта это сильная позиция: команда понимает не только код, но и экономику масштабирования.

Факторы роста сметы и риски

Что может заметно увеличить бюджет

Сценарий	Оценка	Пояснение
Полнотекстовая AI-обработка всех статей	> 63 млн ₽ разово	Если анализировать не только title + abstract, а весь текст статьи чанками, стоимость резко возрастает.
Локальное зеркалирование всего PDF-архива	+ 28-41 тыс. ₽/мес	При хранении порядка 12-18 ТБ PDF в объектном хранилище.
Массовый перевод всего корпуса	+ ≈ 5,6 млн ₽ разово	Если в baseline включить сплошной машинный перевод title + abstract для всего исторического массива.

Рекомендация для экспертного обсуждения

Для экономического слайда и разговора с экспертом оптимально брать две главные цифры: около 18 млн ₽ на запуск и около 2,3 млн ₽ в год на поддержку. Это выглядит реалистично, защищено и показывает понимание того, что основная стоимость проекта связана с AI-обработкой всего массива статей.

Основание расчета: ключевые публичные источники

- arXiv: Monthly Submissions и Annual Reports (масштаб архива и темп пополнения).
- CyberLeninka: каталог журналов и публичные описания масштаба библиотеки.
- ChinaXiv / связанные библиотечные и институциональные страницы: публичные оценки объема архива.
- Yandex Cloud: тарифы Compute Cloud, Managed PostgreSQL, Object Storage, VPC.
- Yandex AI Studio / YandexGPT 5 Pro: тарифы на входящие и исходящие токены.
- Yandex Translate: тарифы на машинный перевод.

Краткие ссылки для проверки

arxiv.org/show_monthly_submissions
info.arxiv.org/about/reports/
cyberleninka.ru/journal
chinaxiv.org
yandex.cloud/ru/docs/compute/pricing
yandex.cloud/ru/docs/managed-postgresql/pricing
yandex.cloud/ru/docs/storage/pricing
yandex.cloud/ru/docs/vpc/pricing
aistudio.yandex.ru/docs/ru/ai-studio/pricing.html
yandex.cloud/ru/docs/translate/pricing